

FACTIBILIDAD DE PROYECTOS DATA DRIVEN · ENTREGABLE 2

Del dato crudo al dataset de entrenamiento

Casa Óga · riesgo de dead stock por SKU y tienda · datos a agosto de 2026

Grupo 1 · Gerónimo Fasce · Gianfranco Di Claudio · Matías Fleischer · Simón Volpato Escandarani · Santiago Hernández


15 fuentes, 56 meses, una segunda entrega de datos

15 fuentes: ventas, stock, catálogo, OC, transferencias, liquidaciones, promociones, presupuesto y más	299.400 filas en Ventas y en Stock, a nivel mes · tienda · SKU	56 meses de ene-2022 a ago-2026	800 × 28 SKUs por tiendas
--	--	---	---

2026 llegó después: verificamos que no rompiera lo anterior

Son los mismos archivos con 8 meses más. El tramo 2022-2025 quedó idéntico: mismas filas y mismos totales (\$32.538,4 M y 750.538 unidades). El diagnóstico histórico sigue vigente y todo se recalculó al nuevo corte. Tres fuentes no acompañan: Devoluciones, Calendario y el catálogo.

El promedio esconde el problema: la cola se engorda



5,0 meses

mediana de cobertura: no se mueve en todo el período

16 → 48

meses en el percentil 99 entre dic-25 y ago-26

213 → 882

posiciones con más de 12 meses de stock; \$184,1 M a costo en ago-26


Mapa de calidad: 15 fuentes × 7 dimensiones

Fuente	Comple.	Consist.	Exactitud	Actualidad	Validez	Unicidad	Trazab.
Ventas	OK	Crítico	Crítico	OK	Menor	Crítico	Menor
Stock tiendas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Catálogo	Menor	OK	OK	Crítico	OK	Crítico	Crítico
Tiendas	OK	Crítico	Crítico	OK	OK	OK	OK
Calendario	OK	OK	OK	Crítico	OK	OK	OK
Liquidaciones	OK	Crítico	Menor	OK	Menor	OK	OK
Devoluciones	OK	OK	OK	Crítico	OK	OK	OK
Historial precios	Menor	Crítico	Menor	OK	OK	OK	Crítico
Órdenes de compra	OK	OK	OK	OK	OK	OK	OK
Presupuesto	Menor	Menor	Menor	OK	Menor	OK	Menor
Promociones	Menor	OK	Crítico	OK	Crítico	Crítico	Menor
Proveedores	OK	OK	OK	OK	OK	OK	OK
Stock depósito	OK	Menor	OK	OK	OK	OK	OK
Transferencias	OK	Crítico	OK	OK	OK	OK	OK
Costo almacenam.	OK	Menor	OK	Menor	OK	OK	Menor

Por qué tratamos cada problema así

Problema	Qué hicimos	Por qué
Claves duplicadas	Conservar la 1ra ocurrencia	Con cualquier otro criterio los totales no cierran
Stock negativo	Llevar a 0	Error de sincronización confirmado (P14-P16)
Venta negativa	Netear con la venta del mes	Son devoluciones reales, no ritmo de venta (P23)
Descuentos > 100% o < 0%	Excluir del margen	Error de carga, sin acción comercial detrás (P24-P28)
Presupuesto en 0 o negativo	Excluir del desvío	Proceso inmaduro en 2022 y error de carga (P29-P32)
Historial de precios	No usarlo	Es una reconstrucción, no un registro (P9-P10)
Comparar entre años	En unidades, sin deflactar	La venta ya está a precio actual: IPC corregiría dos veces
22 SKUs sin costo	Costo de OC × 1,2321	Supuesto sugerido por el negocio y declarado (P3-P7)

Corregir cambia poco los totales y mucho el detalle



- < 2%**
cambian venta, unidades y capital al corregir
- +1,5 pp**
gana Decoración al unificar categorías: es la candidata al piloto
- +26%**
prevalencia del target según cómo se traten las devoluciones: el mayor impacto para el modelo

LA PREGUNTA QUE RESPONDE EL MODELO

¿Esta posición SKU–tienda va a tener más de 12 meses de stock dentro de 3 meses?

Binaria: 1 = sí

Cobertura = stock / promedio de 12 meses de unidades netas


Sin SKUs discontinuados

Por qué este target y no otro

Candidato	Positivos	Casos nuevos	Recall de «sigue igual»	Veredicto
Dead stock binario (3 condiciones OR)	8,51%	58%	41,8%	Descartado: mucha inercia
Cobertura > 12 o discontinuado	3,85%	71%	28,6%	Discontinuados cambian en 2026
Sin ventas en 3 meses	6,75%	58%	42,2%	Descartado: inercial y ruidoso
Cobertura > 12, sin discontinuados	3,38%	68%	32,5%	Elegido
Cobertura > 9 (rojo + amarillo)	9,84%	64%	35,9%	Alternativa si falta volumen

Cómo leerlo: «recall de sigue igual» es cuántos casos acierta una regla que solo dice «la posición va a estar como está hoy». Si es alto, el target es inercia y un modelo no aporta. Con el elegido, el 68% de los positivos son casos nuevos.

La prevalencia salta en 2026: la partición tiene que ser temporal



Train

t de dic-22 a dic-24 · 48.631 filas · 1,78%

Validación

t de abr-25 a sep-25 · 28.895 filas · 1,94%

Test

t de ene-26 a may-26 · 25.888 filas · 9,03%

Entre bloques, 3 meses de embargo (igual al horizonte): ninguna etiqueta de train cae en el período de validación.

Qué información ve el modelo al predecir

Historia hasta el cierre del mes t : se puede usar

Ventas y stock de los últimos 12 meses · OC recibidas y OC pedidas que siguen pendientes · transferencias y liquidaciones ya ocurridas · promociones vigentes · presupuesto cumplido · catálogo con fecha de baja $\leq t$

$t+1$ a $t+3$: no se puede

Venta, stock, liquidaciones, transferencias y presupuesto futuros. Solo se mira el calendario comercial fijo (Hot Sale, Black Friday, Navidad).

$t+3$: se mide la etiqueta

t

Además: transformaciones ajustadas solo con train, embargo de 3 meses entre bloques y discontinuados fuera del universo.


67 variables en 8 grupos, cada uno con su porqué

Demanda · 16 Unidades de t, t-1, t-2, 3, 6 y 12 meses, máximo, variabilidad, tendencia, meses sin venta, precio y descuento realizados. Es donde está la señal: la rotación de la posición.	Stock · 8 Disponible, en tránsito, variación a 3 meses, cobertura actual y de hace 3 meses, capital inmovilizado. La trayectoria anticipa el cruce del umbral.	SKU en la cadena · 8 Stock y cobertura del SKU en las 28 tiendas y en depósito, tiendas en rojo, tendencia del SKU. El problema es de producto y de compra, no de tienda.	Contexto de tienda · 6 Tendencia de la tienda y de la categoría, peso de la posición, % de posiciones en rojo, cumplimiento presupuestario. Separa un problema del producto de uno de la tienda.
Abastecimiento · 9 OC recibidas y pendientes, meses desde la última OC, transferencias, lead time y pedido mínimo. Lo que entra es lo que genera el sobrestock.	Acciones comerciales · 7 Liquidación activa y su descuento, liquidaciones de la posición y del SKU, promociones de la categoría. Registran lo que ya se hizo sobre la posición.	Producto · 7 Precio, precio relativo a la subcategoría, margen, antigüedad; categoría, subcategoría, proveedor. Contexto y palanca de Compras (proveedor).	Tienda y calendario · 5 m², región, formato; mes del año y eventos fijos en el horizonte. Segmentación y estacionalidad, que el modelo verifica.

Lo que quedó afuera, y por qué

Leakage Venta y stock de t+1 a t+3. definen el target Liquidaciones, transferencias y OC posteriores a t. son reacciones al sobrestock Estado del catálogo. es una foto de hoy: revela bajas futuras Presupuesto futuro. se reajusta con la venta real (P31) Promociones futuras. no hay evidencia de que se planifiquen con anticipación	Calidad Antigüedad de tienda. 6 tiendas venden antes de abrir (H3) Precio del historial. reconstrucción retroactiva (H8) Devoluciones por motivo. no hay datos de 2026 (H12) Temporada y feriados. el Calendario no cubre 2026 (H12)	Generalización y otros Id de tienda y de SKU. el modelo memorizaría posiciones Marca de costo imputado. constante en train; queda como control Costo de almacenamiento. constante por categoría Cliente o ticket. no existe en ninguna fuente
--	--	---

Con la misma capacidad, el modelo encuentra más casos



62% vs 47%

casos capturados con 420 alertas por mes: modelo contra ordenar por cobertura actual

76% vs 57%

con 700 alertas por mes

Modelo de prueba (gradient boosting sin ajustar) entrenado en train y medido en validación. No es el modelo final.

PRÓXIMO PASO · ENTREGABLE 3

Modelar sobre un dataset que ya sabemos que tiene señal

Regresión logística como línea base explicable y gradient boosting como alternativa.

Umbral elegido por capacidad operativa, no por un corte de probabilidad.

Evaluación en 2026 para medir robustez ante el cambio de régimen.