

FACTIBILIDAD DE PROYECTOS DATA DRIVEN · ENTREGABLE 2

Del dato crudo al dataset de entrenamiento

Casa Óga · riesgo de dead stock por SKU y tienda · datos a agosto de 2026

Grupo 1 · Gerónimo Fasce · Gianfranco Di Claudio · Matías Fleischer · Simón Volpato Escandarani · Santiago Hernández

Cuatro preguntas, en este orden

1 · ¿Qué dicen los datos?

EDA de las 15 fuentes al corte ago-2026. Qué se confirma del TP1, qué no, y qué cambió en 2026.

2 · ¿Se puede confiar en ellos?

Mapa de calidad, 12 hallazgos, los criterios acordados con el negocio y cuánto cambia el análisis al corregir.

3 · ¿Qué vamos a predecir?

La variable objetivo, por qué esa y no otra, y qué tan sólida es cada decisión detrás.

4 · ¿Con qué datos?

El dataset de entrenamiento: 60 variables sin leakage, las que quedaron afuera y por qué, y si tiene señal.

15 fuentes, 56 meses, una segunda entrega de datos

15 fuentes: ventas, stock, catálogo, OC, transferencias, liquidaciones, promociones, presupuesto y más	299.400 filas en Ventas y en Stock, a nivel mes · tienda · SKU	56 meses de ene-2022 a ago-2026	800 × 28 SKUs por tiendas
--	--	---	---

2026 llegó después: verificamos que no rompiera lo anterior


Son los mismos archivos con 8 meses más. El tramo 2022-2025 quedó idéntico: mismas filas y mismos totales (\$32.538,4 M y 750.538 unidades). El diagnóstico histórico sigue vigente y todo se recalculó al nuevo corte. Tres fuentes no acompañan: Devoluciones, Calendario y el catálogo.

PARTE 1

Qué dicen los datos

EDA al corte ago-2026: crecimiento, estacionalidad, cobertura y el cambio de 2026.

El negocio creció sumando posiciones, no vendiendo más por posición



\$40.083 M

vendidos entre ene-2022 y ago-2026,
con devoluciones neteadas


17 → 8.073

posiciones SKU-tienda con venta entre
ene-22 y dic-25

~3,2


unidades por posición y mes, planas
todo el período (línea punteada)

Dos cifras del TP1 que no se sostienen con los datos



No hay estacionalidad


El «143 en diciembre vs 61 en enero» era el crecimiento del año. Ajustado por tendencia, todos los meses quedan entre 98 y 106.



La cobertura no «mejoró»: está estable

El 10,6 → 5,2 del TP1 sale solo de dividir por un promedio de 12 meses que incluye el arranque de 2022. Con cualquier otra medida: ~5,2 meses todo el período.

2026: la venta cae y el stock no acompaña



-13,2%


venta ene-ago 2026 contra el mismo período de 2025 (unidades -12,7%, posiciones -8,1%)

-20% → -8%

la caída es de nivel: arranca fuerte en enero y se achica mes a mes

Comparación en bruto: 2026 no trae devoluciones registradas, netear solo 2025 la sesgaría.

El promedio esconde el problema: la cola se engorda



5,0 meses

mediana de cobertura: no se mueve en todo el período

16 → 48

meses en el percentil 99 entre dic-25 y ago-26

213 → 882

posiciones con más de 12 meses de stock; \$184,1 M a costo en ago-26

Por qué: en 2026 la venta cae 13,2% contra 2025 y el stock no se ajusta. Las posiciones que ya rotaban poco acumulan meses de stock.

PARTE 2

Calidad y limpieza

Qué está mal, cómo lo tratamos, por qué, y cuánto cambia el resultado al corregir.

Mapa de calidad: 15 fuentes × 7 dimensiones

Fuente	Comple.	Consist.	Exactitud	Actualidad	Validez	Unicidad	Trazab.
Ventas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Stock tiendas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Catálogo	Crítico	Menor	OK	Crítico	OK	Crítico	Crítico
Tiendas	OK	Crítico	Crítico	OK	OK	OK	OK
Calendario	OK	OK	OK	Crítico	OK	OK	OK
Liquidaciones	OK	Crítico	Menor	OK	Menor	OK	OK
Devoluciones	OK	OK	OK	Crítico	OK	OK	OK
Historial precios	Menor	Crítico	Menor	OK	OK	OK	Crítico
Órdenes de compra	OK	OK	OK	OK	OK	OK	OK
Presupuesto	Menor	Crítico	Menor	OK	Menor	OK	Menor
Promociones	Menor	Menor	Menor	OK	Menor	Menor	Menor
Proveedores	OK	OK	OK	OK	OK	OK	OK
Stock depósito	OK	Menor	OK	OK	OK	OK	OK
Transferencias	OK	Menor	OK	OK	OK	OK	OK
Costo almacenam.	OK	Menor	OK	Menor	OK	OK	Menor

OK

no se detectó ningún problema (los nulos esperables no cuentan).

Menor

el problema existe pero no cambia ningún resultado: pocos registros que se excluyen, un campo que no se usa o una corrección mecánica.

Crítico

sin tratarlo cambia un KPI, el target o una variable del modelo, o usar el dato exige un supuesto o la confirmación del negocio.

Doce hallazgos, cada uno con su tratamiento

H1 · Claves duplicadas 2.378 en Ventas y en Stock, solo 2022-25. Tratamiento: Conservar la 1ra ocurrencia. Causa raíz: H2.	H2 · SKUs duplicados 15 SKUs cargados dos veces, difieren solo en proveedor. Tratamiento: Error del sistema (P11). Costo único de catálogo.	H3 · Venta antes de abrir 6 tiendas, 11.058 filas, \$1.471,7 M. Tratamiento: Sin respuesta. No usar antigüedad de tienda.
H4 · Negativos imposibles 2.317 ventas y 1.209 stocks negativos. Tratamiento: Stock: piso en 0 (P16). Ventas: netear devoluciones (P23).	H5 · Venta sin stock 1.020 filas con venta y stock 0; 187 en 2026. Tratamiento: Misma causa que H4: desfase POS–inventario.	H6 · Tránsito sin conciliar 8.771 uds vs 936 de transferencias (9×). Tratamiento: Campo sin definición: queda fuera del modelo.

Doce hallazgos, cada uno con su tratamiento (cont.)

H7 · Liquidaciones incoherentes 90 de 108 «Discontinuación» sobre SKUs activos; tienda «Todas». Tratamiento: Se usan solo como historia hasta t.	H8 · Precios vs historial Precio de venta > 1,5× el histórico en 33% de filas. Tratamiento: Historial reconstruido (P9-P10): no se usa.	H9 · Descuentos y presupuesto 5 descuentos fuera de 0-100%; 309 ceros y 3 negativos. Tratamiento: Excluir del margen y del desvío (P28, P32).
H10 · Promociones inválidas Ids repetidos y 2 con fin antes del inicio. Tratamiento: Se excluyen del cálculo de promociones.	H11 · 22 SKUs sin costo No se puede valorar su stock ni su margen. Tratamiento: Costo de OC × 1,2321, supuesto declarado.	H12 · Fuentes sin 2026 Devoluciones, Calendario y catálogo cortan en 2025. Tratamiento: Se declara; no se usan como features.


Por qué tratamos cada problema así

Problema	Qué hicimos	Por qué
Claves duplicadas	Conservar la 1ra ocurrencia	Con cualquier otro criterio los totales no cierran
Stock negativo	Llevar a 0	Error de sincronización confirmado (P14-P16)
Venta negativa	Netear con la venta del mes	Son devoluciones reales, no ritmo de venta (P23)
Descuentos > 100% o < 0%	Excluir del margen	Error de carga, sin acción comercial detrás (P24-P28)
Presupuesto en 0 o negativo	Excluir del desvío	Proceso inmaduro en 2022 y error de carga (P29-P32)
Historial de precios	No usarlo	Es una reconstrucción, no un registro (P9-P10)
Comparar entre años	En unidades, sin deflactar	La venta ya está a precio actual: IPC corregiría dos veces
22 SKUs sin costo	Costo de OC × 1,2321	Supuesto sugerido por el negocio y declarado (P3-P7)

El costo de 22 SKUs es un supuesto, y lo decimos



Corregir cambia poco los totales y mucho el detalle



- < 2%**
cambian venta, unidades y capital al corregir
- +1,5 pp**
gana Decoración al unificar categorías: es la candidata al piloto
- 2,6% → 3,4%**
prevalencia del target al netear las devoluciones en vez de llevarlas a 0 (P23): +30% de positivos, el mayor impacto para el modelo

PARTE 3

La variable objetivo

Qué predecimos, por qué esa definición y qué tan firme es cada decisión detrás.

LA PREGUNTA QUE RESPONDE EL MODELO

¿Esta posición SKU–tienda va a tener más de 12 meses de stock dentro de 3 meses?

Binaria: 1 = sí

Cobertura = stock / promedio de 12 meses de unidades netas

Sin SKUs discontinuados

Seis decisiones definen el target

Unidad: SKU–tienda–mes Es donde se decide: liquidar, transferir o frenar la reposición de un producto en una tienda.	Universo Posiciones con stock en t, no discontinuadas, con al menos 3 meses de historia y observadas en t+3. Con 12 meses se perdían los productos nuevos.	Horizonte: 3 meses Confirmado por el negocio: menos se confunde con ruido; la acción tarda de 2 a 4 semanas.
Umbral: 12 meses Rotación anual < 1 (non-moving en el análisis FSN) y compatible con 420-700 intervenciones por mes.	Prevalencia: 3,40% 6.853 positivos en 201.306 filas. 2,5% hasta 2025, 9% en 2026.	Métrica: recall El negocio declaró más costoso no ver un caso (falso negativo) que revisar uno de más.

Por qué este target y no otro

Candidato	Positivos	Casos nuevos	Recall de «sigue igual»	Veredicto
Dead stock binario (3 condiciones OR)	8,32%	62%	38,4%	Mezcla criterios; arrastra el ruido de «sin venta»
Cobertura > 12 o discontinuado	3,99%	67%	33,5%	No hay discontinuados en 2026
Sin ventas en 3 meses	6,18%	65%	35,3%	Criterio de consumo masivo; 22% por azar
Cobertura > 12, sin discontinuados	3,40%	61%	38,6%	Elegido
Cobertura > 9 (rojo + amarillo)	9,93%	62%	38,5%	Alternativa si falta volumen


Cómo leerlo: «recall de sigue igual» es cuántos casos acierta una regla que solo dice «la posición va a estar como está hoy». Con el universo de 3+ meses todos quedan entre 34% y 39%: la inercia ya no decide. Elegimos por negocio: umbral relativo a la rotación de cada SKU (lo pidió Comercial), sin discontinuados (en 2026 no hay) y un evento sobre el que se puede actuar.

Qué tan firme es cada decisión, dicho con honestidad

Decisión	En qué se apoya	Solidez
Cobertura como métrica	El negocio pidió un umbral relativo a la rotación de cada SKU	Firme
Horizonte de 3 meses	Confirmado por el negocio	Firme
Priorizar recall	El negocio declaró el falso negativo como más costoso	Firme
Corte en 12 meses	Capacidad operativa + rotación anual < 1 (FSN)	Media
Devoluciones neteadas	Default del negocio (P23)	Media
Corte amarillo en 9 meses	Solo el percentil 90 de nuestra distribución	Débil
Acciones por banda	Asignación nuestra, sin respaldo externo	Débil

Pendiente de aprobación de María G. (Comercial). Le pedimos cambiar el semáforo 30/70 que ya había aprobado: marca en rojo al 74% del catálogo contra una capacidad de 420-700 intervenciones por mes.

La prevalencia salta en 2026: la partición tiene que ser temporal



Train

t de mar-22 a dic-24 · 98.649 filas · 2,50%

Validación

t de abr-25 a sep-25 · 38.362 filas · 2,23%

Test

t de ene-26 a may-26 · 28.070 filas · 9,03%

Entre bloques, 3 meses de embargo (igual al horizonte): ninguna etiqueta de train cae en el período de validación.

PARTE 4

El dataset de entrenamiento

Qué información ve el modelo, qué variables entran, cuáles no y por qué.

dataset_entrenamiento_v3

201.306	60	6.853	9.818
filas SKU–tienda–mes	features: 55 numéricas y 5 categóricas	positivos (3,40%)	posiciones · 750 SKUs · 28 tiendas

11 de las 15 fuentes, unidas en un panel mensual

Ventas ∝ Stock por (mes, tienda, SKU) es la base. Se suman catálogo y proveedores por SKU; tiendas por tienda; depósito y OC por (mes, SKU); transferencias y liquidaciones por (mes, tienda, SKU); promociones por (mes, categoría); presupuesto por (mes, tienda, categoría). Ninguna fuente tiene datos personales: no aplica anonimización (Ley 25.326).

Se genera con Modelo/construir_dataset_modelo.py desde Datasets_Normalizados: reproducible de punta a punta.

Qué información ve el modelo al predecir

Historia hasta el cierre del mes t : se puede usar

Ventas y stock de los últimos 12 meses · OC recibidas y OC pedidas que siguen pendientes · transferencias y liquidaciones ya ocurridas · promociones vigentes · presupuesto cumplido · catálogo con fecha de baja $\leq t$

$t+1$ a $t+3$: no se puede

Venta, stock, liquidaciones, transferencias y presupuesto futuros. Solo se mira el calendario comercial fijo (Hot Sale, Black Friday, Navidad).

$t+3$: se mide la etiqueta

t

Además: transformaciones ajustadas solo con train, embargo de 3 meses entre bloques y discontinuados fuera del universo.

60 variables en 8 grupos, cada uno con su porqué

Demanda e historia · 14

Unidades de t, t-1, t-2, 3, 6 y 12 meses, máximo, variabilidad, tendencia, meses con y sin venta, antigüedad de la posición e indicador de historia corta.

Es donde está la señal: la rotación de la posición.

Stock · 5

Disponible, variación a 3 meses, cobertura actual y de hace 3 meses, cambio de cobertura.

La trayectoria anticipa el cruce del umbral.

SKU en la cadena · 8

Stock y cobertura del SKU en las 28 tiendas y en depósito, tiendas en rojo, tendencia del SKU.

El problema es de producto y de compra, no de tienda.

Contexto de tienda · 6

Tendencia de la tienda y de la categoría, peso de la posición, % de posiciones en rojo, cumplimiento presupuestario.

Separa un problema del producto de uno de la tienda.

Abastecimiento · 10

OC recibidas y pendientes, meses desde la última OC, transferencias recibidas y enviadas, lead time y pedido mínimo.

Lo que entra es lo que genera el sobrestock.

Acciones comerciales · 7

Liquidación activa y su descuento, liquidaciones de la posición y del SKU, promociones de la categoría.

Registran lo que ya se hizo sobre la posición.

Producto · 5

Precio relativo a la subcategoría, antigüedad del SKU; categoría, subcategoría, proveedor.

Contexto y palanca de Compras (proveedor).

Tienda y calendario · 5

m², región, formato; mes del año y eventos fijos en el horizonte.

Segmentación y estacionalidad, que el modelo verifica.

Lo que quedó afuera, y por qué

Leakage Venta y stock de t+1 a t+3. definen el target Liquidaciones, transferencias y OC posteriores a t. son reacciones al sobrestock Estado del catálogo. es una foto de hoy: revela bajas futuras Presupuesto futuro. se reajusta con la venta real (P31) Promociones futuras. no hay evidencia de que se planifiquen con anticipación	Calidad Antigüedad de tienda. 6 tiendas venden antes de abrir (H3) Precio, costo y margen del catálogo. son el valor de hoy: anacrónicos para meses pasados Precio del historial. reconstrucción retroactiva (H8) Stock en tránsito. sin definición y sin señal en 2026 (H6) Devoluciones por motivo. no hay datos de 2026 (H12) Temporada y feriados. el Calendario no cubre 2026 (H12)	Generalización y otros Id de tienda y de SKU. el modelo memorizaría posiciones Marca de costo imputado. constante en train; queda como control Costo de almacenamiento. constante por categoría Cliente o ticket. no existe en ninguna fuente
--	--	---

Transformaciones, todas ajustadas solo con train

Transformación	Qué se hizo	Por qué
Valores extremos	Winsorización p1-p99 en 45 continuas	Colas largas reales, no errores: no se borran filas
Distribuciones sesgadas	$\log(1+x)$ en 25 variables	Reduce el peso de los extremos (cobertura: asimetría 3,98)
Escalado	Estandarización con media y desvío de train	Escalas muy distintas; lo necesita la regresión logística
Categóricas	One-hot de categoría, subcategoría, región, formato, proveedor	Son nominales: label encoding inventaría un orden
Temporales	Mes como seno y coseno, ventanas de 3/6/12 meses, antigüedad	Diciembre queda junto a enero; la trayectoria anticipa
Faltantes	Topes, indicadores y medianas de train	Son denominadores cero o eventos ausentes, no datos perdidos
Balanceo	Ponderación de clases (≈ 55), sin SMOTE	SMOTE mezclaría meses y rompería la estructura temporal

Dos versiones: sin transformar para árboles y transformada para una regresión logística, que es la línea base explicable que exige el negocio.

PARTE 5

¿El dataset tiene señal?

Antes de modelar: qué separa a las posiciones que van a caer en rojo, y qué agrega un modelo sobre el semáforo actual.

La tendencia multiplica el riesgo


	cae >50%	cae 20-50%	estable	sube >20%
>12 meses	35,7%	7,1%	12,4%	20,2%
9-12 meses	9,4%	4,4%	4,0%	5,5%
6-9 meses	4,6%	1,9%	1,3%	2,3%
3-6 meses	2,1%	0,8%	0,5%	0,7%
<3 meses	1,4%	0,9%	0,4%	0,7%

% que cae en rojo 3 meses después. Filas: cobertura hoy. Columnas: venta de 3 meses vs promedio de 12.

4,0% → 9,4%
riesgo con 9-12 meses de cobertura
si la venta está estable o si cae más
de 50%

55%
de los casos hoy no está en rojo: un
semáforo sobre el presente no los ve

El modelo encuentra más casos en 2025; en 2026 la ventaja se achica



58% vs 47%


casos capturados con 420 alertas por mes en validación (2025): modelo contra ordenar por cobertura actual

59% vs 58%

en test (2026) con 420 alertas: la regla casi lo alcanza. Con 700: 81% vs 74%

Con 420 alertas acierta 1 de cada 5 en 2025 (precisión 20%). En 2026 hay 507 casos por mes: más que la capacidad. Modelo de prueba sin ajustar, no el final.

La señal está en la demanda de la posición



30 de 55


variables numéricas no separan solas (AUC < 0,55):
liquidaciones, promociones, OC y transferencias

0,61 → 0,50

AUC de la antigüedad de la posición de train a test: en
2026 no hay productos nuevos (catálogo congelado)

Se mantienen todas: pueden aportar en combinación. La
selección se hace en el modelado.

Cuánto capital está en posiciones con más de 12 meses de stock



\$184,1 M

a costo en 882 posiciones y 363 SKUs, ago-26

\$9,2 M/mes

de costo de sostenerlo, al 5% mensual declarado por el negocio

25,4%

del capital en rojo está en 20 SKUs: el problema es de producto

Limitaciones que declaramos y lo que queda pendiente

Limitaciones

- 2026 sin devoluciones.** el neteo es asimétrico entre años (H12)
- Precio y costo.** el catálogo guarda solo el valor actual: se usa solo el precio relativo
- Posiciones con < 3 meses.** fuera del modelo: requieren una regla aparte
- Venta antes de abrir.** 6 tiendas sin explicación (H3)
- Capacidad de 15-25 por tienda.** nunca se midió
- Costo de 22 SKUs.** supuesto, no dato

Pendientes

- María G.** aprobar target, cortes y acciones por banda
- Lucía O.** confirmar la capacidad operativa
- Negocio.** responder H3, H6 y H12; extender Devoluciones, Calendario y catálogo a 2026
- Equipo.** decidir si el motivo «sin rotación» (devolución a proveedor) se netea

PRÓXIMO PASO · ENTREGABLE 3

Modelar sobre un dataset que ya sabemos que tiene señal

Regresión logística como línea base explicable y gradient boosting como alternativa.

Umbral elegido por capacidad operativa, no por un corte de probabilidad.

Evaluación en 2026 para medir robustez ante el cambio de régimen.