

FACTIBILIDAD DE PROYECTOS DATA DRIVEN · ENTREGABLE 2

Del dato crudo al dataset de entrenamiento

Casa Óga · riesgo de dead stock por SKU y tienda · datos a agosto de 2026

Grupo 1 · Gerónimo Fasce · Gianfranco Di Claudio · Matías Fleischer · Simón Volpato Escandarani · Santiago Hernández


15 fuentes, 56 meses, una segunda entrega de datos

15 fuentes: ventas, stock, catálogo, OC, transferencias, liquidaciones, promociones, presupuesto y más	299.400 filas en Ventas y en Stock, a nivel mes · tienda · SKU	56 meses de ene-2022 a ago-2026	800 × 28 SKUs por tiendas
--	--	---	---

2026 llegó después: verificamos que no rompiera lo anterior

Son los mismos archivos con 8 meses más. El tramo 2022-2025 quedó idéntico: mismas filas y mismos totales (\$32.538,4 M y 750.538 unidades). El diagnóstico histórico sigue vigente y todo se recalculó al nuevo corte. Tres fuentes no acompañan: Devoluciones, Calendario y el catálogo.

El promedio esconde el problema: la cola se engorda



5,0 meses

mediana de cobertura: no se mueve en todo el período

16 → 48

meses en el percentil 99 entre dic-25 y ago-26

213 → 882

posiciones con más de 12 meses de stock; \$184,1 M a costo en ago-26

Por qué: en 2026 la venta cae 13,2% contra 2025 y el stock no se ajusta. Las posiciones que ya rotaban poco acumulan meses de stock.

Mapa de calidad: 15 fuentes × 7 dimensiones

Fuente	Comple.	Consist.	Exactitud	Actualidad	Validez	Unicidad	Trazab.
Ventas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Stock tiendas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Catálogo	Crítico	Menor	OK	Crítico	OK	Crítico	Crítico
Tiendas	OK	Crítico	Crítico	OK	OK	OK	OK
Calendario	OK	OK	OK	Crítico	OK	OK	OK
Liquidaciones	OK	Crítico	Menor	OK	Menor	OK	OK
Devoluciones	OK	OK	OK	Crítico	OK	OK	OK
Historial precios	Menor	Crítico	Menor	OK	OK	OK	Crítico
Órdenes de compra	OK	OK	OK	OK	OK	OK	OK
Presupuesto	Menor	Crítico	Menor	OK	Menor	OK	Menor
Promociones	Menor	Menor	Menor	OK	Menor	Menor	Menor
Proveedores	OK	OK	OK	OK	OK	OK	OK
Stock depósito	OK	Menor	OK	OK	OK	OK	OK
Transferencias	OK	Menor	OK	OK	OK	OK	OK
Costo almacenam.	OK	Menor	OK	Menor	OK	OK	Menor

OK

no se detectó ningún problema (los nulos esperables no cuentan).

Menor

el problema existe pero no cambia ningún resultado: pocos registros que se excluyen, un campo que no se usa o una corrección mecánica.


Crítico

sin tratarlo cambia un KPI, el target o una variable del modelo, o usar el dato exige un supuesto o la confirmación del negocio.

Por qué tratamos cada problema así

Problema	Qué hicimos	Por qué
Claves duplicadas	Conservar la 1ra ocurrencia	Con cualquier otro criterio los totales no cierran
Stock negativo	Llevar a 0	Error de sincronización confirmado (P14-P16)
Venta negativa	Netear con la venta del mes	Son devoluciones reales, no ritmo de venta (P23)
Descuentos > 100% o < 0%	Excluir del margen	Error de carga, sin acción comercial detrás (P24-P28)
Presupuesto en 0 o negativo	Excluir del desvío	Proceso inmaduro en 2022 y error de carga (P29-P32)
Historial de precios	No usarlo	Es una reconstrucción, no un registro (P9-P10)
Comparar entre años	En unidades, sin deflactar	La venta ya está a precio actual: IPC corregiría dos veces
22 SKUs sin costo	Costo de OC × 1,2321	Supuesto sugerido por el negocio y declarado (P3-P7)

Corregir cambia poco los totales y mucho el detalle



- < 2%**
cambian venta, unidades y capital al corregir
- +1,5 pp**
gana Decoración al unificar categorías: es la candidata al piloto
- 2,6% → 3,4%**
prevalencia del target al netear las devoluciones en vez de llevarlas a 0 (P23): +30% de positivos, el mayor impacto para el modelo

LA PREGUNTA QUE RESPONDE EL MODELO

¿Esta posición SKU–tienda va a tener más de 12 meses de stock dentro de 3 meses?

Binaria: 1 = sí

Cobertura = stock / promedio de 12 meses de unidades netas


Sin SKUs discontinuados

Por qué este target y no otro

Candidato	Positivos	Casos nuevos	Recall de «sigue igual»	Veredicto
Dead stock binario (3 condiciones OR)	8,32%	62%	38,4%	Mezcla criterios; arrastra el ruido de «sin venta»
Cobertura > 12 o discontinuado	3,99%	67%	33,5%	No hay discontinuados en 2026
Sin ventas en 3 meses	6,18%	65%	35,3%	Criterio de consumo masivo; 22% por azar
Cobertura > 12, sin discontinuados	3,40%	61%	38,6%	Elegido
Cobertura > 9 (rojo + amarillo)	9,93%	62%	38,5%	Alternativa si falta volumen

Cómo leerlo: «recall de sigue igual» es cuántos casos acierta una regla que solo dice «la posición va a estar como está hoy». Con el universo de 3+ meses todos quedan entre 34% y 39%: la inercia ya no decide. Elegimos por negocio: umbral relativo a la rotación de cada SKU (lo pidió Comercial), sin discontinuados (en 2026 no hay) y un evento sobre el que se puede actuar.

La prevalencia salta en 2026: la partición tiene que ser temporal



Train

t de mar-22 a dic-24 · 98.649 filas · 2,50%

Validación

t de abr-25 a sep-25 · 38.362 filas · 2,23%

Test

t de ene-26 a may-26 · 28.070 filas · 9,03%

Entre bloques, 3 meses de embargo (igual al horizonte): ninguna etiqueta de train cae en el período de validación.

Qué información ve el modelo al predecir

Historia hasta el cierre del mes t : se puede usar

Ventas y stock de los últimos 12 meses · OC recibidas y OC pedidas que siguen pendientes · transferencias y liquidaciones ya ocurridas · promociones vigentes · presupuesto cumplido · catálogo con fecha de baja $\leq t$

$t+1$ a $t+3$: no se puede

Venta, stock, liquidaciones, transferencias y presupuesto futuros. Solo se mira el calendario comercial fijo (Hot Sale, Black Friday, Navidad).

$t+3$: se mide la etiqueta

t

Además: transformaciones ajustadas solo con train, embargo de 3 meses entre bloques y discontinuados fuera del universo.

60 variables en 8 grupos, cada uno con su porqué

Demanda e historia · 14

Unidades de t, t-1, t-2, 3, 6 y 12 meses, máximo, variabilidad, tendencia, meses con y sin venta, antigüedad de la posición e indicador de historia corta.

Es donde está la señal: la rotación de la posición.

Stock · 5

Disponible, variación a 3 meses, cobertura actual y de hace 3 meses, cambio de cobertura.

La trayectoria anticipa el cruce del umbral.

SKU en la cadena · 8

Stock y cobertura del SKU en las 28 tiendas y en depósito, tiendas en rojo, tendencia del SKU.

El problema es de producto y de compra, no de tienda.

Contexto de tienda · 6

Tendencia de la tienda y de la categoría, peso de la posición, % de posiciones en rojo, cumplimiento presupuestario.

Separa un problema del producto de uno de la tienda.

Abastecimiento · 10

OC recibidas y pendientes, meses desde la última OC, transferencias recibidas y enviadas, lead time y pedido mínimo.

Lo que entra es lo que genera el sobrestock.

Acciones comerciales · 7

Liquidación activa y su descuento, liquidaciones de la posición y del SKU, promociones de la categoría.

Registran lo que ya se hizo sobre la posición.

Producto · 5

Precio relativo a la subcategoría, antigüedad del SKU; categoría, subcategoría, proveedor.

Contexto y palanca de Compras (proveedor).

Tienda y calendario · 5

m², región, formato; mes del año y eventos fijos en el horizonte.

Segmentación y estacionalidad, que el modelo verifica.

Lo que quedó afuera, y por qué


Leakage Venta y stock de t+1 a t+3. definen el target Liquidaciones, transferencias y OC posteriores a t. son reacciones al sobrestock Estado del catálogo. es una foto de hoy: revela bajas futuras Presupuesto futuro. se reajusta con la venta real (P31) Promociones futuras. no hay evidencia de que se planifiquen con anticipación	Calidad Antigüedad de tienda. 6 tiendas venden antes de abrir (H3) Precio, costo y margen del catálogo. son el valor de hoy: anacrónicos para meses pasados Precio del historial. reconstrucción retroactiva (H8) Stock en tránsito. sin definición y sin señal en 2026 (H6) Devoluciones por motivo. no hay datos de 2026 (H12) Temporada y feriados. el Calendario no cubre 2026 (H12)	Generalización y otros Id de tienda y de SKU. el modelo memorizaría posiciones Marca de costo imputado. constante en train; queda como control Costo de almacenamiento. constante por categoría Cliente o ticket. no existe en ninguna fuente
--	--	---

Transformaciones, todas ajustadas solo con train

Transformación	Qué se hizo	Por qué
Valores extremos	Winsorización p1-p99 en 45 continuas	Colas largas reales, no errores: no se borran filas
Distribuciones sesgadas	$\log(1+x)$ en 25 variables	Reduce el peso de los extremos (cobertura: asimetría 3,98)
Escalado	Estandarización con media y desvío de train	Escalas muy distintas; lo necesita la regresión logística
Categóricas	One-hot de categoría, subcategoría, región, formato, proveedor	Son nominales: label encoding inventaría un orden
Temporales	Mes como seno y coseno, ventanas de 3/6/12 meses, antigüedad	Diciembre queda junto a enero; la trayectoria anticipa
Faltantes	Topes, indicadores y medianas de train	Son denominadores cero o eventos ausentes, no datos perdidos
Balanceo	Ponderación de clases (≈ 55), sin SMOTE	SMOTE mezclaría meses y rompería la estructura temporal

Dos versiones: sin transformar para árboles y transformada para una regresión logística, que es la línea base explicable que exige el negocio.

El modelo encuentra más casos en 2025; en 2026 la ventaja se achica



58% vs 47%

casos capturados con 420 alertas por mes en validación (2025): modelo contra ordenar por cobertura actual

59% vs 58%

en test (2026) con 420 alertas: la regla casi lo alcanza. Con 700: 81% vs 74%

Con 420 alertas acierta 1 de cada 5 en 2025 (precisión 20%). En 2026 hay 507 casos por mes: más que la capacidad. Modelo de prueba sin ajustar, no el final.

PRÓXIMO PASO · ENTREGABLE 3

Modelar sobre un dataset que ya sabemos que tiene señal

Regresión logística como línea base explicable y gradient boosting como alternativa.

Umbral elegido por capacidad operativa, no por un corte de probabilidad.

Evaluación en 2026 para medir robustez ante el cambio de régimen.