

FACTIBILIDAD DE PROYECTOS DATA DRIVEN · ENTREGABLE 2

Del dato crudo al dataset de entrenamiento

Casa Óga · riesgo de dead stock por SKU y tienda · datos a agosto de 2026

Grupo 1 · Gerónimo Fasce · Gianfranco Di Claudio · Matías Fleischer · Simón Volpato Escandarani · Santiago Hernández

Mapa de calidad: 15 fuentes × 6 dimensiones

Fuente	Comple.	Exactitud	Actualidad	Validez	Unicidad	Trazab.
Ventas	OK	Crítico	OK	Crítico	Crítico	Menor
Stock tiendas	OK	Crítico	OK	Crítico	Crítico	Menor
Catálogo	Crítico	OK	Crítico	OK	Crítico	Crítico
Tiendas	OK	Crítico	OK	OK	OK	OK
Calendario	OK	OK	Crítico	OK	OK	OK
Liquidaciones	OK	Menor	OK	Menor	OK	OK
Devoluciones	OK	OK	Crítico	OK	OK	OK
Historial precios	Menor	Menor	OK	OK	OK	Crítico
Órdenes de compra	OK	OK	OK	OK	OK	OK
Presupuesto	Menor	Menor	OK	Menor	OK	Menor
Promociones	Menor	Menor	OK	Menor	Menor	Menor
Proveedores	OK	OK	OK	OK	OK	OK
Stock depósito	OK	OK	OK	OK	OK	OK
Transferencias	OK	OK	OK	OK	OK	OK
Costo almacenam.	OK	OK	Menor	OK	OK	Menor

OK

no se detectó ningún problema (los nulos esperables no cuentan).

Menor

el problema existe pero no cambia ningún resultado: pocos registros que se excluyen, un campo que no se usa o una corrección mecánica.


Crítico

sin tratarlo cambia un KPI, el target o una variable del modelo, o usar el dato exige un supuesto o la confirmación del negocio.

Por qué tratamos cada problema así

Problema	Qué hicimos	Por qué
Claves duplicadas	Conservar la 1ra ocurrencia	Con cualquier otro criterio los totales no cierran
Stock negativo	Llevar a 0	Error de sincronización confirmado
Venta negativa	Netear con la venta del mes	Son devoluciones reales, no ritmo de venta
Descuentos > 100% o < 0%	Excluir del margen	Error de carga, sin acción comercial detrás
Presupuesto en 0 o negativo	Excluir del desvío	Proceso inmaduro en 2022 y error de carga
Historial de precios	No usarlo	Es una reconstrucción, no un registro
Comparar entre años	En unidades, sin deflactar	La venta ya está a precio actual: IPC corregiría dos veces
22 SKUs sin costo	Costo de OC × 1,2321	Supuesto sugerido por el negocio y declarado

Corregir cambia poco los totales y mucho el detalle



- < 2%**
cambian venta, unidades y capital al corregir
- +1,5 pp**
gana Decoración al unificar categorías: es la candidata al piloto
- 2,6% → 3,4%**
prevalencia del target al netear las devoluciones en vez de llevarlas a 0: +30% de positivos, el mayor impacto para el modelo

15 fuentes y 56 meses de datos

15

fuentes: ventas, stock, catálogo, OC, promociones y más

299.400


filas mes · tienda · SKU en Ventas y en Stock

56

meses, de ene-2022 a ago-2026


800 × 28

SKUs × tiendas



-13,2% venta ene-ago 2026 contra 2025

Dos tercios de la caída son productos dados de baja a fin de 2025



0 altas

ningún SKU nuevo desde jul-25 (entre 138 y 235 por año hasta 2025)


2 de cada 3

pesos de la caída ene-ago (\$815 M de \$1.213 M) son los 96 SKUs discontinuados a fin de 2025: 8,9 de los 13,2 puntos

-4,8%

en los 634 SKUs que siguen: de -9% en enero a -1% en agosto

Las posiciones sin venta crecen 2,5 veces en un trimestre y casi no se liquidan



365 → 929
posiciones activas con stock y sin ninguna venta en 3 meses (dic-25 → ago-26); \$33,3 M → \$111,8 M a costo

-51%
liquidaciones ene-ago contra 2025 (175 → 85); por sobrestock, 37 → 8

4 de 929
posiciones sin venta tuvieron alguna liquidación en 2026

Las compras de estos SKUs no se movieron: -1,2% en unidades ene-jul.

LA PREGUNTA QUE RESPONDE EL MODELO

¿Esta posición SKU–tienda va a tener más de 12 meses de stock dentro de 3 meses?

Binaria: 1 = sí

Cobertura = stock / promedio de 12 meses de unidades netas

Sin SKUs discontinuados

¿Por qué 3 meses?

Liquidar o transferir tarda de 2 a 4 semanas. Lo confirmó el negocio.

¿Por qué 12 meses?

Rota menos de una vez al año y deja 420-700 alertas por mes, lo que Operaciones puede atender.

Métrica: recall


Para el negocio, no ver un caso cuesta más que revisar uno de más.

Por qué este target y no otro

Candidato	Positivos	Casos nuevos	Recall de «sigue igual»	Veredicto
Dead stock binario (3 condiciones OR)	8,32%	62%	38,4%	Mezcla criterios; arrastra el ruido de «sin venta»
Cobertura > 12 o discontinuado	3,99%	67%	33,5%	No hay discontinuados en 2026
Sin ventas en 3 meses	6,18%	65%	35,3%	Criterio de consumo masivo; 22% por azar
Cobertura > 12, sin discontinuados	3,40%	61%	38,6%	Elegido
Cobertura > 9 (rojo + amarillo)	9,93%	62%	38,5%	Alternativa si falta volumen

Cómo leerlo: «sigue igual» es una regla que dice «la posición va a estar como está hoy»; «casos nuevos» son los que esa regla no ve: 6 de cada 10 positivos hoy todavía no lo son, y ahí aporta el modelo. Como los cinco quedan entre 34% y 39%, elegimos por negocio: umbral relativo a la rotación de cada SKU (lo pidió Comercial), sin discontinuados (en 2026 no hay) y un evento sobre el que se puede actuar.

La prevalencia salta en 2026: la partición tiene que ser temporal



El modelo solo ve lo que se sabía al cierre del mes t

Al cierre del mes t predecimos si, en $t+3$, la posición tendrá **más de 12 meses de cobertura**.

Hasta t : se usa

- Toda la información disponible hasta ese momento
- Ventas, stock, compras, transferencias, promociones

Después de t : no se usa

- Nada de $t+1$ en adelante
- Ni las variables que hoy están cargadas pero hablan del futuro

En $t+3$

Se mide la respuesta

Regla: si una variable habla del futuro, no entra al modelo.

60 variables en 8 grupos, cada uno con su porqué

Demanda e historia · 14 SALE DE: VENTAS Unidades de t, t-1, t-2, 3, 6 y 12 meses, máximo, variabilidad, tendencia, meses con y sin venta, antigüedad de la posición, historia corta. Mide cuánto rota la posición: si se vende poco, el stock se acumula.	Stock · 5 SALE DE: STOCK Y VENTAS Disponible, variación a 3 meses, cobertura actual y de hace 3 meses, cambio de cobertura. Muestra si la cobertura viene subiendo hacia los 12 meses.	SKU en la cadena · 8 SALE DE: STOCK DE TIENDAS Y DEPÓSITO Stock y cobertura del SKU en las 28 tiendas y en depósito, tiendas en rojo, tendencia del SKU. Muestra si el exceso es del producto en toda la cadena, no de una sola tienda.	Contexto de tienda · 6 SALE DE: VENTAS, STOCK, PRESUPUESTO Tendencia de la tienda y de la categoría, peso de la posición, % de posiciones en rojo, cumplimiento presupuestario. Distingue si el problema es del producto o de la tienda.
Abastecimiento · 10 SALE DE: OC, TRANSFERENCIAS, PROVEEDORES OC recibidas y pendientes, meses desde la última OC, transferencias recibidas y enviadas, lead time y pedido mínimo. Muestra cuánto entró y cuánto está por llegar: más compra, más sobrestock.	Acciones comerciales · 7 SALE DE: LIQUIDACIONES, PROMOCIONES Liquidación activa y su descuento, liquidaciones de la posición y del SKU, promociones de la categoría. Muestra si ya se intentó vender la posición con liquidaciones o promociones.	Producto · 5 SALE DE: CATÁLOGO Precio relativo a la subcategoría, antigüedad del SKU; categoría, subcategoría, proveedor. Describe el producto y su proveedor, sobre el que Compras puede actuar.	Tienda y calendario · 5 SALE DE: TIENDAS Y FECHA m², región, formato; mes del año y eventos fijos en el horizonte. Cuenta el tipo de tienda y la época del año, porque la venta cambia con la estacionalidad.

Lo que quedó afuera, y por qué


1 · Parecen del presente, pero hablan del futuro Engañan porque ya están cargadas: Presupuesto de los meses siguientes Es un plan que parece conocido de antemano, pero se actualiza con la venta real Estado actual del catálogo Es el de hoy: marca como discontinuados productos que en ese mes seguían activos	2 · Datos no confiables Están mal o incompletos: Antigüedad de tienda 6 tiendas venden antes de abrir Precio y costo del catálogo Son los de hoy, no los de ese mes Devoluciones por motivo y calendario No hay datos de 2026	3 · No le sirven al modelo No describen la posición: Id de tienda y de SKU Identifican, no describen: el modelo memorizaría Costo de almacenamiento y marca de costo imputado Son constantes
---	---	---

Transformaciones, todas ajustadas solo con train

Transformación	Qué se hizo	Por qué
Valores extremos	Winsorización p1-p99 en 45 continuas	Colas largas reales, no errores: no se borran filas
Distribuciones sesgadas	log(1+x) en 25 variables	Reduce el peso de los extremos (cobertura: asimetría 3,98)
Escalado	Estandarización con media y desvío de train	Escalas muy distintas; lo necesita la regresión logística
Categóricas	One-hot de categoría, subcategoría, región, formato, proveedor	Son nominales: label encoding inventaría un orden
Temporales	Mes como seno y coseno, ventanas de 3/6/12 meses, antigüedad	Diciembre queda junto a enero; la trayectoria anticipa
Faltantes	Topes, indicadores y medianas de train	Son denominadores cero o eventos ausentes, no datos perdidos
Balanceo	Ponderación de clases (≈55), sin SMOTE	SMOTE mezclaría meses y rompería la estructura temporal

Dos versiones: sin transformar para árboles y transformada para una regresión logística, que es la línea base explicable que exige el negocio.

El modelo encuentra más casos en 2025; en 2026 la ventaja se achica



58% vs 47%

casos capturados con 420 alertas por mes en validación (2025): modelo contra ordenar por cobertura actual

59% vs 58%

en test (2026) con 420 alertas: la regla casi lo alcanza. Con 700: 81% vs 74%

Con 420 alertas acierta 1 de cada 5 en 2025 (precisión 20%). En 2026 hay 507 casos por mes: más que la capacidad. Modelo de prueba sin ajustar, no el final.

PRÓXIMO PASO · ENTREGABLE 3

Modelar sobre un dataset que ya sabemos que tiene señal

Regresión logística como línea base explicable y gradient boosting como alternativa.

Umbral elegido por capacidad operativa, no por un corte de probabilidad.

Evaluación en 2026 para medir robustez ante el cambio de régimen.