

FACTIBILIDAD DE PROYECTOS DATA DRIVEN · ENTREGABLE 2

Del dato crudo al dataset de entrenamiento

Casa Óga · riesgo de dead stock por SKU y tienda · datos a agosto de 2026

Grupo 1 · Gerónimo Fasce · Gianfranco Di Claudio · Matías Fleischer · Simón Volpato Escandarani · Santiago Hernández

15 fuentes y 56 meses de datos

15

fuentes: ventas, stock, catálogo, OC, promociones y más

299.400


filas mes · tienda · SKU en Ventas y en Stock

56

meses, de ene-2022 a ago-2026


800 × 28

SKUs × tiendas



-13,2% venta ene-ago 2026 contra 2025

Dos tercios de la caída vienen de productos que ya no están



2 de cada 3

pesos de la caída ene-ago (\$815 M de \$1.213 M) son los 96 SKUs discontinuados a fin de 2025: 8,9 de los 13,2 puntos

-4,8%


en los 634 SKUs que siguen: de -9% en enero a -1% en agosto

0 altas

ningún SKU nuevo desde jul-25 (entre 138 y 235 por año hasta 2025)

El target excluye los discontinuados: la caída que ve el modelo es la línea azul.

El promedio esconde el problema: la cola se engorda



5,0 meses

mediana de cobertura: no se mueve en todo el período

16 → 48


meses en el percentil 99 entre dic-25 y ago-26

213 → 882

posiciones con más de 12 meses de stock; \$184,1 M a costo en ago-26

Por qué: no es la caída general (dos tercios son SKUs dados de baja, fuera del target). Es un grupo de posiciones que dejó de vender a comienzos de 2026 y no se liquidó.

Las posiciones sin venta crecen 2,5 veces en un trimestre y casi no se liquidan



365 → 929
posiciones activas con stock y sin ninguna venta en 3 meses (dic-25 → ago-26); \$33,3 M → \$111,8 M a costo

-51%
liquidaciones ene-ago contra 2025 (175 → 85); por sobrestock, 37 → 8

4 de 929
posiciones sin venta tuvieron alguna liquidación en 2026

Las compras de estos SKUs no se movieron: -1,2% en unidades ene-jul.

Mapa de calidad: 15 fuentes × 7 dimensiones

Fuente	Comple.	Consist.	Exactitud	Actualidad	Validez	Unicidad	Trazab.
Ventas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Stock tiendas	OK	Crítico	Crítico	OK	Crítico	Crítico	Menor
Catálogo	Crítico	Menor	OK	Crítico	OK	Crítico	Crítico
Tiendas	OK	Crítico	Crítico	OK	OK	OK	OK
Calendario	OK	OK	OK	Crítico	OK	OK	OK
Liquidaciones	OK	Crítico	Menor	OK	Menor	OK	OK
Devoluciones	OK	OK	OK	Crítico	OK	OK	OK
Historial precios	Menor	Crítico	Menor	OK	OK	OK	Crítico
Órdenes de compra	OK	OK	OK	OK	OK	OK	OK
Presupuesto	Menor	Crítico	Menor	OK	Menor	OK	Menor
Promociones	Menor	Menor	Menor	OK	Menor	Menor	Menor
Proveedores	OK	OK	OK	OK	OK	OK	OK
Stock depósito	OK	Menor	OK	OK	OK	OK	OK
Transferencias	OK	Menor	OK	OK	OK	OK	OK
Costo almacenam.	OK	Menor	OK	Menor	OK	OK	Menor

OK

no se detectó ningún problema (los nulos esperables no cuentan).

Menor

el problema existe pero no cambia ningún resultado: pocos registros que se excluyen, un campo que no se usa o una corrección mecánica.


Crítico

sin tratarlo cambia un KPI, el target o una variable del modelo, o usar el dato exige un supuesto o la confirmación del negocio.

Por qué tratamos cada problema así

Problema	Qué hicimos	Por qué
Claves duplicadas	Conservar la 1ra ocurrencia	Con cualquier otro criterio los totales no cierran
Stock negativo	Llevar a 0	Error de sincronización confirmado
Venta negativa	Netear con la venta del mes	Son devoluciones reales, no ritmo de venta
Descuentos > 100% o < 0%	Excluir del margen	Error de carga, sin acción comercial detrás
Presupuesto en 0 o negativo	Excluir del desvío	Proceso inmaduro en 2022 y error de carga
Historial de precios	No usarlo	Es una reconstrucción, no un registro
Comparar entre años	En unidades, sin deflactar	La venta ya está a precio actual: IPC corregiría dos veces
22 SKUs sin costo	Costo de OC × 1,2321	Supuesto sugerido por el negocio y declarado

Corregir cambia poco los totales y mucho el detalle



- < 2%**
cambian venta, unidades y capital al corregir
- +1,5 pp**
gana Decoración al unificar categorías: es la candidata al piloto
- 2,6% → 3,4%**
prevalencia del target al netear las devoluciones en vez de llevarlas a 0: +30% de positivos, el mayor impacto para el modelo

LA PREGUNTA QUE RESPONDE EL MODELO

¿Esta posición SKU–tienda va a tener más de 12 meses de stock dentro de 3 meses?

Binaria: 1 = sí

Cobertura = stock / promedio de 12 meses de unidades netas

Sin SKUs discontinuados

¿Por qué 3 meses?

Liquidar o transferir tarda de 2 a 4 semanas. Lo confirmó el negocio.

¿Por qué 12 meses?

Rota menos de una vez al año y deja 420-700 alertas por mes, lo que Operaciones puede atender.

Métrica: recall


Para el negocio, no ver un caso cuesta más que revisar uno de más.

Por qué este target y no otro

Candidato	Positivos	Casos nuevos	Recall de «sigue igual»	Veredicto
Dead stock binario (3 condiciones OR)	8,32%	62%	38,4%	Mezcla criterios; arrastra el ruido de «sin venta»
Cobertura > 12 o discontinuado	3,99%	67%	33,5%	No hay discontinuados en 2026
Sin ventas en 3 meses	6,18%	65%	35,3%	Criterio de consumo masivo; 22% por azar
Cobertura > 12, sin discontinuados	3,40%	61%	38,6%	Elegido
Cobertura > 9 (rojo + amarillo)	9,93%	62%	38,5%	Alternativa si falta volumen

Cómo leerlo: «sigue igual» es una regla que dice «la posición va a estar como está hoy»; «casos nuevos» son los que esa regla no ve: 6 de cada 10 positivos hoy todavía no lo son, y ahí aporta el modelo. Como los cinco quedan entre 34% y 39%, elegimos por negocio: umbral relativo a la rotación de cada SKU (lo pidió Comercial), sin discontinuados (en 2026 no hay) y un evento sobre el que se puede actuar.

La prevalencia salta en 2026: la partición tiene que ser temporal



Qué información ve el modelo al predecir

Historia hasta el cierre del mes t : se puede usar

Ventas y stock de los últimos 12 meses · OC recibidas y OC pedidas que siguen pendientes · transferencias y liquidaciones ya ocurridas · promociones vigentes · presupuesto cumplido · catálogo con fecha de baja $\leq t$

$t+1$ a $t+3$: no se puede

Venta, stock, liquidaciones, transferencias y presupuesto futuros. Solo se mira el calendario comercial fijo (Hot Sale, Black Friday, Navidad).

$t+3$: se mide la etiqueta

t

Además: transformaciones ajustadas solo con train, embargo de 3 meses entre bloques y discontinuados fuera del universo.

60 variables en 8 grupos, cada uno con su porqué

Demanda e historia · 14

Unidades de t, t-1, t-2, 3, 6 y 12 meses, máximo, variabilidad, tendencia, meses con y sin venta, antigüedad de la posición e indicador de historia corta.

Es donde está la señal: la rotación de la posición.

Stock · 5

Disponible, variación a 3 meses, cobertura actual y de hace 3 meses, cambio de cobertura.

La trayectoria anticipa el cruce del umbral.

SKU en la cadena · 8

Stock y cobertura del SKU en las 28 tiendas y en depósito, tiendas en rojo, tendencia del SKU.

El problema es de producto y de compra, no de tienda.

Contexto de tienda · 6

Tendencia de la tienda y de la categoría, peso de la posición, % de posiciones en rojo, cumplimiento presupuestario.

Separa un problema del producto de uno de la tienda.

Abastecimiento · 10

OC recibidas y pendientes, meses desde la última OC, transferencias recibidas y enviadas, lead time y pedido mínimo.

Lo que entra es lo que genera el sobrestock.

Acciones comerciales · 7

Liquidación activa y su descuento, liquidaciones de la posición y del SKU, promociones de la categoría.

Registran lo que ya se hizo sobre la posición.

Producto · 5

Precio relativo a la subcategoría, antigüedad del SKU; categoría, subcategoría, proveedor.

Contexto y palanca de Compras (proveedor).

Tienda y calendario · 5

m², región, formato; mes del año y eventos fijos en el horizonte.

Segmentación y estacionalidad, que el modelo verifica.

Lo que quedó afuera, y por qué


Leakage Venta y stock de t+1 a t+3. definen el target Liquidaciones, transferencias y OC posteriores a t. son reacciones al sobrestock Estado del catálogo. es una foto de hoy: revela bajas futuras Presupuesto futuro. se reajusta con la venta real (P31) Promociones futuras. no hay evidencia de que se planifiquen con anticipación	Calidad Antigüedad de tienda. 6 tiendas venden antes de abrir (H3) Precio, costo y margen del catálogo. son el valor de hoy: anacrónicos para meses pasados Precio del historial. reconstrucción retroactiva (H8) Stock en tránsito. sin definición y sin señal en 2026 (H6) Devoluciones por motivo. no hay datos de 2026 (H12) Temporada y feriados. el Calendario no cubre 2026 (H12)	Generalización y otros Id de tienda y de SKU. el modelo memorizaría posiciones Marca de costo imputado. constante en train; queda como control Costo de almacenamiento. constante por categoría Cliente o ticket. no existe en ninguna fuente
--	--	---

Transformaciones, todas ajustadas solo con train

Transformación	Qué se hizo	Por qué
Valores extremos	Winsorización p1-p99 en 45 continuas	Colas largas reales, no errores: no se borran filas
Distribuciones sesgadas	log(1+x) en 25 variables	Reduce el peso de los extremos (cobertura: asimetría 3,98)
Escalado	Estandarización con media y desvío de train	Escalas muy distintas; lo necesita la regresión logística
Categóricas	One-hot de categoría, subcategoría, región, formato, proveedor	Son nominales: label encoding inventaría un orden
Temporales	Mes como seno y coseno, ventanas de 3/6/12 meses, antigüedad	Diciembre queda junto a enero; la trayectoria anticipa
Faltantes	Topes, indicadores y medianas de train	Son denominadores cero o eventos ausentes, no datos perdidos
Balanceo	Ponderación de clases (≈55), sin SMOTE	SMOTE mezclaría meses y rompería la estructura temporal

Dos versiones: sin transformar para árboles y transformada para una regresión logística, que es la línea base explicable que exige el negocio.

El modelo encuentra más casos en 2025; en 2026 la ventaja se achica



58% vs 47%

casos capturados con 420 alertas por mes en validación (2025): modelo contra ordenar por cobertura actual

59% vs 58%

en test (2026) con 420 alertas: la regla casi lo alcanza. Con 700: 81% vs 74%

Con 420 alertas acierta 1 de cada 5 en 2025 (precisión 20%). En 2026 hay 507 casos por mes: más que la capacidad. Modelo de prueba sin ajustar, no el final.

PRÓXIMO PASO · ENTREGABLE 3

Modelar sobre un dataset que ya sabemos que tiene señal

Regresión logística como línea base explicable y gradient boosting como alternativa.

Umbral elegido por capacidad operativa, no por un corte de probabilidad.

Evaluación en 2026 para medir robustez ante el cambio de régimen.