



Instituto Tecnológico
de Buenos Aires

Unidad 3:

A - Factibilidad técnica ← acá estamos

¿Tenemos los datos, la calidad, las herramientas y las personas para que el proyecto funcione?

C - Factibilidad legal y riesgos

¿Podemos usar estos datos tal como está diseñado el proyecto? ¿Qué puede salir mal?

B- Factibilidad económica

¿Los beneficios esperados justifican la inversión? Costos, beneficios, ROI y escenarios.

D - Diseño de la solución y go-live

¿Cómo llega el modelo a una decisión de negocio?
Presentación del documento final.

En paralelo empieza el modelado predictivo:

una etapa por clase, sobre el dataset de entrenamiento del Entregable 2.

Cada etapa aporta evidencia a la factibilidad que se evalúa ese mismo día.

FACTIBILIDAD TÉCNICA

¿Tiene esta empresa las condiciones técnicas suficientes para que este proyecto funcione?

Definición

Evaluar la factibilidad técnica no es solo listar sistemas y datos. Es responder una pregunta concreta con evidencia del caso.

¿Qué esperamos como respuesta?

- No es un sí o un no
- Es un diagnóstico estructurado
- Termina en un veredicto justificado

¿Qué significa evaluar la factibilidad técnica?

Condición 1 · Datos suficientes

¿Existen los datos que el modelo necesita? ¿Cubren el período histórico necesario? ¿Tienen la granularidad correcta (por tienda, por producto, por fecha)?

Condición 2 · Calidad utilizable

¿Los datos tienen una calidad mínima para entrenar un modelo? Los errores, nulos y duplicados no impiden el proyecto, pero requieren un esfuerzo para ser corregidos.

Condición 3 · Infraestructura y herramientas accesibles

¿Hay herramientas disponibles para procesar, modelar y visualizar? ¿Son compatibles con las capacidades del equipo?

Condición 4 · Capacidad humana para sostenerlo

¿Hay alguien que pueda construir el modelo? ¿Y alguien que pueda mantenerlo una vez en producción? Un modelo sin responsable muere en semanas.

DATOS SUFICIENTES

Condición 1 · ¿Existen los datos que el modelo necesita?

Pregunta guía	Dónde buscar la evidencia	Señal de alerta
¿Existe historial suficiente para entrenar el modelo? ¿Cuántos períodos? ¿Cuántos eventos del fenómeno que queremos predecir?	Archivos transaccionales del caso. Contar registros por período y casos positivos del target.	Menos de 2 años de historial o menos de 50 a 100 eventos del fenómeno a predecir.
¿Los datos existen al nivel de granularidad que el modelo necesita? (ej.: tienda-mes, cliente-mes, SKU-tienda-mes)	Revisar el esquema de cada archivo. ¿Tiene fecha y las claves de la unidad de análisis?	Los datos están agregados y no se pueden desagregar sin perder información.
¿Las fuentes necesarias están todas disponibles o hay alguna que falta?	Cruzar lo que el modelo necesita con lo que existe. Si el modelo necesita margen y no hay costos, hay un problema.	Falta alguna fuente clave sin la cual no se puede calcular la variable target.

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: hay ventas de marzo de 2022 a diciembre de 2025 (24.240 transacciones) y presupuesto para 720 tienda-mes (15 tiendas × 48 meses), con la granularidad que pide el modelo. Pero los costos no tienen fecha de vigencia, así que el margen histórico solo puede aproximarse. Y falta contar cuántos tienda-mes terminaron con margen bajo: muchas filas no garantizan muchos eventos.

CALIDAD UTILIZABLE

Condición 2 · ¿Los datos tienen la calidad mínima para entrenar un modelo?

Pregunta guía	Dónde buscar la evidencia	Señal de alerta
¿Qué porcentaje de registros clave tienen valores faltantes en variables críticas?	EDA: contar nulos por columna en cada archivo.	Más del 20 a 30% de nulos en la variable target o en las features principales.
¿Los identificadores son consistentes entre fuentes? ¿El código de una misma entidad coincide en todos los archivos?	Hacer un join entre las fuentes principales. Ver cuántos registros no matchean.	Más del 10% de registros no matchean entre fuentes: datos maestros fragmentados.
¿Los errores detectados en el EDA son corregibles con trabajo razonable o son estructurales?	Resumen de errores del EDA (Entregable 2). Clasificar los errores por tipo y frecuencia.	Errores que requieren re-relevamiento manual o que el negocio no sabe explicar.

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: ventas y presupuesto identifican las tiendas como T01 a T15; el maestro de tiendas, como S001 a S028. El join directo matchea 0%. En cambio, productos contra costos matchea 99,96%.

Además, en 5.395 de 24.240 ventas (22%) la venta neta no coincide con precio neto × unidades. Son errores corregibles, pero la tabla de equivalencias de tiendas la tiene que validar el negocio.

INFRAESTRUCTURA Y HERRAMIENTAS

Condición 3 · ¿Hay herramientas accesibles para procesar, modelar y visualizar?

Pregunta guía	Dónde buscar la evidencia	Señal de alerta
¿Las herramientas necesarias para construir el pipeline y el modelo están disponibles o son accesibles dentro del presupuesto?	Comparar el stack necesario con el presupuesto disponible.	El stack mínimo viable supera el presupuesto o requiere licencias que la empresa no puede sostener.
¿Cómo se integran los datos hoy? ¿Es manual, semi-automático o automático? ¿Puede escalar a producción?	Preguntar al equipo operativo. Revisar si hay APIs, exports programados o si todo es copiar y pegar.	Integración 100% manual sin plan de automatización: el modelo no puede actualizarse sin intervención humana constante.
¿Dónde se ejecutarán la integración y la transformación de los datos? (equipo local, servidor propio, nube)	Relevar con Sistemas qué entorno existe hoy y quién lo administra.	No hay un entorno definido: el pipeline termina viviendo en la computadora de una persona.

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: los indicadores se consolidan a mano en planillas de cálculo, a partir de los reportes de cada sistema (POS, promociones, inventario, contable). Alcanza para un MVP mensual, no para producción.

Un stack open source entra en el presupuesto de USD 30.000, pero hay que definir dónde corre y quién lo opera.

CAPACIDAD HUMANA

Condición 4 · ¿Hay quien pueda construir el modelo y quien pueda sostenerlo?

Pregunta guía	Dónde buscar la evidencia	Señal de alerta
¿Hay alguien que pueda construir el modelo? ¿Perfil interno o externo? ¿Con qué dedicación?	Relevamiento de perfiles del equipo. Si no hay perfil interno, evaluar si el presupuesto cubre un consultor.	Nadie en la organización tiene el perfil técnico y el presupuesto no alcanza para un externo con dedicación suficiente.
¿Quién va a mantener el modelo en producción? ¿Hay un responsable nombrado?	Preguntar explícitamente a la Dirección. Si la respuesta es "no sé" o "el mismo consultor", es una señal de riesgo.	No hay nadie designado para monitorear, reentrenar y corregir el modelo una vez entregado.

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: el caso indica que no existen roles formales de gestión y gobierno de datos, y que los usuarios clave tienen poco tiempo para validar.

El presupuesto puede cubrir un consultor para construir el modelo, pero nadie está nombrado para mantenerlo. Un modelo sin responsable muere en semanas.

Del diagnóstico al veredicto: ¿por qué puntuar?

Para que la evaluación sea comparable y justificable.

Sin un criterio explícito, dos personas pueden observar los mismos datos y llegar a conclusiones opuestas.

Una escala simple (1 a 3 por condición) fuerza a tomar posición y a justificarla con evidencia.

Puntaje	Significado	Implicancia para el proyecto
1	Condición ausente o crítica: el problema es estructural y no es resoluble dentro del alcance del proyecto.	Bloquea o requiere rediseño del proyecto. Si una condición llega a 1, el proyecto tal como está planteado no puede ejecutarse.
2	Condición débil pero superable: hay un problema real que requiere trabajo adicional, pero está dentro del alcance con esfuerzo y costo estimables.	Agrega costo, tiempo o riesgo al proyecto. Debe aparecer en el plan y en el presupuesto.
3	Condición satisfecha: no hay obstáculos relevantes en esta dimensión. El proyecto puede avanzar sin trabajo adicional significativo.	No agrega riesgo ni costo extraordinario. Es una fortaleza del proyecto.

Del diagnóstico al veredicto: niveles de factibilidad

1,0 a 1,5

NO FACTIBLE

El proyecto no puede ejecutarse con las condiciones actuales. Requiere intervención previa o rediseño del alcance.

1,6 a 2,0

FACTIBILIDAD BAJA

Posible, pero con riesgo alto. Avanzar requiere resolver condiciones críticas primero y contingencias importantes.

2,1 a 2,5

FACTIBILIDAD MEDIA

Viable con condiciones. Las brechas son superables dentro del alcance, pero agregan costo y tiempo que deben estar contemplados.

2,6 a 3,0

FACTIBILIDAD ALTA

Las condiciones técnicas están dadas. El proyecto puede avanzar con riesgos acotados y manejables.

Ejemplo resuelto: del diagnóstico al veredicto

Casa Óga, Proyecto Rentabilidad en Tiendas · una resolución posible, para discutir

Condición	Evidencia del caso	Score
Datos suficientes	720 tienda-mes y casi 4 años de historia. Costos sin fecha de vigencia: el margen histórico es aproximado.	2
Calidad utilizable	IDs de tienda distintos entre fuentes (T01 vs. S001): join directo 0%. Venta neta inconsistente en 22% de las filas. Corregible, con validación del negocio.	2
Infraestructura	Consolidación manual en planillas. Stack open source dentro del presupuesto, sin entorno de ejecución definido.	2
Capacidad humana	Construcción cubierta con un consultor externo. Sin responsable de mantenimiento nombrado.	2
PROMEDIO GLOBAL	Factibilidad baja: posible, pero con riesgo alto	2,0

Condiciones para avanzar: validar la tabla de equivalencias de tiendas, definir cómo se aproxima el costo histórico y nombrar un responsable de mantenimiento. Si alguna no se resuelve, esa condición baja a 1 y el proyecto se bloquea.

Lo que no puede faltar en el veredicto

Veredicto justificado

Score global, nivel de factibilidad y la condición que más pesa en la decisión. ¿Con qué condiciones concretas podría avanzar el proyecto?

Inventario de fuentes con su rol

Cada fuente es crítica (sin ella no se puede calcular el target), útil (enriquece el modelo) u opcional.

Condiciones para avanzar

Qué hay que hacer, quién lo resuelve, en qué momento del cronograma y qué pasa si no se resuelve.

Stack acorde al nivel de factibilidad

Si la factibilidad es baja, un MVP manual antes de automatizar. Indicar herramienta, costo y dónde corre cada capa.

¿Dónde entra el modelado en CRISP-DM?

Entendimiento de Negocio

Entregable 1. Ya definieron el problema, el objetivo del modelo y los stakeholders.

Entendimiento y Preparación de Datos

Entregable 2. EDA, calidad de datos y dataset de entrenamiento listo.

Modelado ← acá empezamos

Entregable 3. Planteo del experimento, baseline, comparación de modelos y ajuste, en cuatro etapas.

Evaluación / Implementación

¿El modelo sirve para la decisión de negocio? Diseño de la solución y requerimientos de go-live.

El modelado en cuatro etapas

Etapa	Clase	Qué se hace	Qué aporta a la factibilidad
1	Hoy, 06/10	Planteo del experimento, control de leakage, métrica y baseline	Evidencia para Datos suficientes y Calidad utilizable
2	13/10	Entrenamiento y comparación de 2 a 3 modelos contra el baseline	Sustento del beneficio esperado y del ROI
3	20/10	Ajuste de hiperparámetros, umbral de decisión, explicabilidad y análisis de errores	Sustento de la explicabilidad (legal) y de los riesgos propios del modelo
4	27/10	Evaluación final en test y ficha del modelo	Insumo del diseño de la solución, del go-live y del veredicto integrado

Objetivo de la Etapa 1: no es conseguir un buen modelo. Es dejar bien planteado el experimento y fijar el piso contra el que se va a comparar todo lo que venga después.

FICHA DEL EXPERIMENTO

¿Qué vamos a predecir exactamente, sobre qué unidad y con cuánta anticipación?

Definición

Una página que fija, antes de entrenar, qué se predice, sobre qué unidad de análisis, con qué datos y con qué horizonte. Si la ficha cambia, cambia el experimento.

¿Qué preguntas hacemos?

- ¿Cuál es el target y con qué regla exacta se calcula?
- ¿Cuál es la unidad de análisis?
- ¿Con cuánta anticipación se predice?
- ¿Cuántos casos positivos hay (prevalencia)?

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: el target es la tienda-mes con margen bruto % por debajo del objetivo presupuestado. Unidad de análisis: tienda-mes. Horizonte: un mes de anticipación.

La regla exacta del target se valida con el negocio antes de modelar.

PARTICIÓN TEMPORAL

¿Con qué datos entreno y con cuáles compruebo si el modelo funciona?

Definición

Se entrena con el pasado y se evalúa con el futuro, igual que va a ocurrir en producción. Una partición aleatoria mezcla períodos y puede inflar los resultados.

¿Qué preguntas hacernos?

- ¿Dónde corto entrenamiento, validación y test?
- ¿Cada conjunto tiene suficientes casos positivos?
- ¿El test queda reservado hasta la Etapa 4?

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: una partición posible



El **modelo aprende** con el pasado, **se ajusta** con validación y **se mide una sola vez** con test, en la Etapa 4.

DATA LEAKAGE

¿El modelo usa información que no tendría en el momento de predecir?

Definición

Hay fuga de información cuando una variable incluye datos que solo se conocen después del evento a predecir. El modelo parece excelente en la prueba y falla en producción.

¿Qué preguntas hacernos?

- ¿Este dato existe en el momento de la predicción?
- ¿Se calcula con información del período a predecir?
- ¿Alguna variable explica el target sospechosamente bien?

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: ¿qué variables puedo usar para predecir el mes siguiente?

Variable candidata	¿Disponible un mes antes?	Decisión
Ventas y margen de los 3 meses anteriores	Sí	Mantener
Presupuesto del mes a predecir	Sí, se define por adelantado	Mantener
Descuento promedio del mes a predecir	No, se conoce al cierre del mes	Recalcular con meses anteriores
Margen real del mes a predecir	No, de ahí sale el target	Excluir

MÉTRICA DE EVALUACIÓN

¿Qué error le cuesta más caro al negocio?

	Modelo dice: margen bajo	Modelo dice: margen normal
Real: margen bajo	Verdadero positivo Tienda en riesgo detectada a tiempo	Falso negativo Tienda en riesgo que nadie vio: margen perdido
Real: margen normal	Falso positivo Alerta falsa: se revisa una tienda que estaba bien	Verdadero negativo Tienda sana, sin alerta

¿Qué métrica mirar?

- **Recall:** de las tiendas en riesgo, ¿cuántas detecté?
- **Precisión:** de mis alertas, ¿cuántas eran reales?
- **F1:** equilibrio entre recall y precisión
- **AUC-ROC:** capacidad de ordenar los casos por riesgo

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: supongamos que 1 de cada 10 tienda-mes termina con margen bajo (72 de 720). Un modelo que siempre responde "margen normal" acierta el 90% de las veces y no detecta ninguna tienda en riesgo.

Cuando la clase a predecir es poco frecuente, la exactitud (accuracy) engaña.

BASELINE

¿Qué tan bien se puede predecir sin un modelo?

Definición

La regla más simple que alguien del negocio podría aplicar hoy. Fija el piso: todo modelo posterior debe justificar su complejidad superándolo.

¿Qué preguntas hacemos?

- ¿Qué regla usaría hoy alguien del negocio?
- ¿Cuánto acierta esa regla en validación?
- ¿Cuánto tiene que mejorar un modelo para justificar su costo?

Ejemplo Casa Óga, Proyecto Rentabilidad en Tiendas: regla de negocio: "si una tienda cerró el mes por debajo del margen objetivo, el mes siguiente también lo hará". Se evalúa en validación junto con el baseline de clase mayoritaria ("ninguna tienda en riesgo").

Si el mejor modelo apenas supera a esta regla, quizás la solución sea la regla.

Para el Entregable 3 · Parte A

Sección 1 · Factibilidad técnica

- Las 4 condiciones, con evidencia del caso
- Scoring (un valor de 1 a 3 por condición) y veredicto
- Inventario de fuentes con su rol
- Condiciones para avanzar y stack tecnológico

Sección 2 · Modelado, Etapa 1

- Ficha del experimento
- Partición temporal, con el test reservado
- Control de data leakage
- Métrica principal y dos baselines

Cada equipo trabaja sobre su caso y sobre el dataset de entrenamiento del Entregable 2. Cada respuesta debe citar el dato, el archivo o la observación que la sustenta.
Adjuntar el notebook o script que reproduce los resultados.



Instituto Tecnológico
de Buenos Aires

MÁS INFORMACIÓN > www.itba.edu.ar