ITBA
Instituto Tecnológicc
de Buenos Aires

EVALUACIÓN DEL MODELO

Factibilidad Legal, riesgos & Evaluacion de Modelos

Caso Rentabilidad en Tienda

Unidad 3: ¿dónde entra la clase de hoy?

Factibilidad técnica

¿Tenemos los datos, la calidad, las herramientas y las personas? Parte A, 06/10.

Factibilidad económica

¿Los beneficios esperados justifican la inversión? Parte B, 13/10.

Evaluación del modelo, legal y riesgos

¿El modelo sirve, vale la plata, se puede usar y qué puede salir mal? Parte C.

Diseño de la solución y go-live

¿Qué solución corresponde y qué hace falta para ponerla en marcha? Parte D.

EVALUAR UN MODELO

Tres lentes, tres preguntas distintas

Nivel 1 · Técnico

· ¿El modelo aprende bien?

· ¿Generaliza?

· ¿Comete errores sistemáticos?

· ¿Es estable en el tiempo?

Nivel 2 · Económico y estratégico

· ¿Cuánto cuesta cada error?

· ¿Cuánto vale una predicción correcta?

· ¿Qué umbral maximiza el valor?

· ¿Quién responde si el modelo falla?

Nivel 3 · Operativo

· ¿El equipo puede actuar sobre las predicciones?

· ¿Las variables existen en producción?

· ¿El sistema soporta el modelo?

· ¿Quién lo monitorea?

Y el marco legal: ¿usa datos personales?, ¿quién toma la decisión final?, ¿se puede justificar?
Clave: un modelo puede aprobar un nivel y reprobar otro. El veredicto sale de mirarlos todos juntos.

Punto de partida: lo que ya sabemos del caso

Fuente	Resultado	Lectura
Parte A · 1.1 a 1.3	Factibilidad técnica 2,0. 125 tienda-mes con margen bajo, concentrados en 2024 y 2025.	Baja
Parte A · 2.4	Métrica principal: F1. Secundarias: precisión, recall y AUC.	Definido
Parte A · 2.5	Baseline (regla: margen del mes anterior < 40%): F1 0,19, recall 0,18.	Piso a superar
Parte B · ROI	Proyecto con modelo: ROI año 1 entre −96% y −81% con la lectura de Finanzas.	No viable
Parte B · MVP	Automatización sin modelo: ROI +33% a 3 años si la reducción del trabajo manual es ≥ 52%.	Con condiciones

La pregunta de hoy: ¿el modelo cambia algo de este panorama, o lo confirma?

NIVEL 1 · TÉCNICO

¿El modelo predice bien, de forma estable y por las razones correctas?

Definición

Evaluar técnicamente un modelo no es mirar un solo número. Es verificar que:

- La métrica sea la adecuada.
- El modelo generalice frente datos que no vio
- Sea estable en el tiempo
- Se pueda explicar.

¿Qué preguntas hacernos?

· ¿La métrica refleja el problema de negocio?
· ¿Hay diferencia entre entrenamiento y validación?
· ¿Los datos de hoy se parecen a los de entrenamiento?
· ¿Qué umbral convierte la probabilidad en decisión?
· ¿Las variables que pesan tienen sentido? ¿Rinde parejo?

Regla de oro: el conjunto de test se mira una sola vez, con el modelo ya elegido.

¿Qué métrica?

Métrica	Qué mide	Cuándo mirarla
Accuracy	Proporción de casos bien clasificados, positivos y negativos.	Solo si las clases están balanceadas.
Recall	De los casos en riesgo reales, cuántos detecta el modelo.	Cuando perder un caso (FN) es caro.
Precisión	De las alertas que emite, cuántas son correctas.	Cuando actuar (revisar) tiene costo.
F1	Equilibrio entre precisión y recall.	Clase minoritaria y ambos errores importan.
AUC-ROC	Capacidad de ordenar casos de mayor a menor riesgo.	Para comparar modelos antes de elegir el umbral. 0,5 = azar.
MSE, MAE, MAPE, R^2	Distancia entre el valor predicho y el real.	Si el target es numérico (ej.: predecir el margen en %).

¿Generaliza? Entrenamiento contra validación

Sobreajuste: el modelo aprende los datos, no el patrón

Definición

Un modelo sobreajustado rinde muy bien con los datos que vió y mal con los nuevos.

Se detecta comparando la métrica en entrenamiento y en validación.

¿Qué preguntas hacernos?

· ¿Cuánto rinde en entrenamiento y cuánto en validación?

· ¿La diferencia crece al hacer el modelo más complejo?

· ¿Cuántos casos positivos tiene el entrenamiento?

· ¿El ajuste de hiperparámetros respetó el orden temporal?

Partición del caso: entrenamiento 2022–2023 · validación 2024 · test 2025 (reservado).
Con datos en el tiempo, la partición también es temporal: se entrena con el pasado y se valida con un período posterior.

VALIDACIÓN CRUZADA

¿Y si la partición de validación fue, por casualidad, la más fácil?

Método	Cómo funciona	Cuándo usarlo
Hold-out	Una sola partición: entrenamiento y validación (ej.: 80-20).	Muchos datos; primera aproximación.
K-fold	Divide en k bloques; entrena con k-1 y valida con el restante, k veces. Promedia.	Datos sin orden temporal.
K-fold estratificado	Igual que k-fold, pero cada bloque mantiene la proporción de clases.	Clase minoritaria (fraude, churn).
Leave-one-out	Cada registro es, una vez, el conjunto de validación.	Muy pocos datos.
Validación temporal	Entrena con el pasado y valida con el período siguiente; la ventana avanza.	Datos en el tiempo: ventas, demanda, márgenes.

Cuidado: con datos en el tiempo, mezclar períodos al azar deja que el modelo "vea el futuro": es leakage temporal.

¿Es estable? El mundo de entrenamiento no es el de hoy

Drift: cuando los datos nuevos no se parecen a los de entrenamiento

Definición

Un modelo aprende la relación entre variables y target en un período. Si el negocio cambia, esa relación deja de valer.

Drift de datos: cambian las variables. Drift de concepto: cambia lo que significa estar en riesgo.

¿Qué preguntas hacernos?

· ¿La proporción de positivos es parecida en todos los períodos?

· ¿Apareció algo nuevo en el negocio (promos, precios, canales)?

· ¿El modelo vio alguna vez la situación actual?

· ¿Cómo y cada cuánto se va a monitorear?

UMBRAL DE DECISIÓN

De la probabilidad a la decisión

Definición

El modelo devuelve una probabilidad. El umbral define a partir de qué valor se actúa. El 0,5 por defecto rara vez es el mejor.

Precisión y recall siempre están en tensión: subir el umbral da más precisión y menos recall; bajarlo, al revés.

¿Qué preguntas hacernos?

· ¿Cuánto cuesta cada falsa alarma y cuánto vale cada acierto?

· ¿Cuántos casos puede revisar el negocio por mes?

· ¿El umbral que maximiza F1 es el que maximiza el valor?

· ¿Las probabilidades están calibradas?

Regla general: si el falso negativo es más caro, se baja el umbral (más recall). Si el falso positivo es más caro, se sube (más precisión). Método formal: calcular el valor esperado en cada umbral y elegir el máximo.

EXPLICABILIDAD

¿Por qué el modelo dice lo que dice?

Definición

Explicabilidad global: qué variables pesan más en el modelo.

Explicabilidad local: por qué un caso puntual fue marcado en riesgo, en lenguaje de negocio.

Una variable que domina de forma sospechosa puede ser leakage.

¿Qué preguntas hacernos?

- ¿Las variables importantes tienen sentido de negocio?
- ¿Hay reglas que nadie podría defender?
- ¿Falta alguna variable que el negocio considera clave?
- ¿Se puede explicar un caso en 80 palabras?

ERRORES POR SEGMENTO

¿El modelo se equivoca parejo?

Definición

La métrica global puede esconder segmentos donde el modelo falla mucho más.

Si las decisiones afectan a personas (encargados, vendedores, clientes), un error desparejo es también un riesgo legal y reputacional.

¿Qué preguntas hacernos?

¿Qué segmentos importan al negocio? (tamaño, región, canal)

¿Cuánto cambia la métrica por segmento?

¿Dónde se concentran las falsas alarmas?

¿Quién paga el costo de ese error?

NIVEL 2 · ECONÓMICO Y ESTRATÉGICO

¿Cuánto vale cada acierto y cuánto cuesta cada error?

Definición

Cada celda de la matriz de confusión tiene un valor económico. El valor neto del modelo es la suma de cada celda por su valor. Es la base del beneficio del ROI.

¿Qué preguntas hacernos?

- ¿Cuánto vale un VP, descontado el costo de actuar?
- ¿Cuánto cuesta un FP?
- ¿FN y VN cambian algo respecto de hoy?
- ¿Contra qué se compara: la situación actual o la regla?

Clave: el costo de actuar se paga en todas las alertas, también en las acertadas.

NIVEL 3 · OPERATIVO

¿Puede la organización hacer algo con las predicciones?

Capacidad de la organización

· ¿Hay un proceso definido para actuar sobre cada alerta?

· ¿El equipo puede absorber el volumen de alertas?

· ¿Hay presupuesto para la acción?

Disponibilidad de los datos

· ¿Cada variable existe en el momento de predecir?

· ¿Está en producción o requiere integración nueva?

· ¿Tiene el mismo formato y latencia?

Capacidad técnica

· ¿Cada cuánto hay que predecir?

· ¿Cuánto puede tardar la respuesta?

· ¿El sistema actual soporta el modelo?

Clave: un modelo que funciona en el notebook puede no funcionar en la operación.

¿Las variables existen cuando hay que predecir?

Variable del modelo	¿Existe al predecir?	¿Disponible en producción?	Observación
Margen del mes anterior	Sí, después del cierre	Con demora	Necesita el costo, que no tiene fecha de vigencia
Margen de 2 y 3 meses atrás	Sí	Sí, una vez consolidado	Mismo problema de costo
Mes del año	Sí	Sí	Sin problema
Ventas del mes anterior	Sí	Sí	Requiere la tabla de equivalencias
Descuento y promociones del mes anterior	Sí	Requiere integración	Hoy son planillas con versiones recuperadas

Lectura: no hay leakage temporal: todas las variables son de meses anteriores. Pero el margen del mes anterior recién existe al cierre (día 5): la alerta llega con una semana del mes ya transcurrida.

¿El sistema soporta el modelo?

Requisito	Un caso de tiempo real (ej.: scoring de crédito)	Rentabilidad en Tienda
Frecuencia de predicción	Cada solicitud, al instante	Una vez por mes, en lote
Volumen	Cientos de solicitudes simultáneas	15 tiendas por mes
Tiempo de respuesta	Menos de 2 segundos	Horas: alcanza con tenerlo el día 5
Infraestructura	Servidor de producción compartido	Máquina virtual chica en la nube
Si el modelo es pesado	Reducir variables, cambiar de algoritmo o escalar	No es un problema

Lectura: en este caso el cuello de botella operativo no es la tecnología: es la capacidad de Finanzas y la disponibilidad del costo.

FACTIBILIDAD LEGAL

¿Podemos usar estos datos y esta decisión automatizada?

Definición

La evaluación legal del modelo mira qué datos usa, quién decide con su resultado y si esa decisión se puede justificar.

Marco de referencia: Ley 25.326 de Protección de Datos Personales y lineamientos de la AAIP sobre IA.

¿Qué preguntas hacernos?

¿El modelo usa datos personales o no?

¿El modelo decide o recomienda?

¿Hay una persona que revisa?

¿Quién accede a datos confidenciales?

¿Se puede rastrear cada dato hasta su origen?

¿Quién es responsable si una decisión es incorrecta?

Las dimensiones legales aplicadas al modelo

Dimensión	Situación del caso	Riesgo
Datos personales	El modelo usa tienda-mes agregado. Las ventas e-commerce con nombre y DNI quedaron fuera de alcance.	Bajo, si se mantiene el alcance.
Seguridad y accesos	Perfiles externos acceden a costos y márgenes: información comercial confidencial.	Medio: requiere acuerdo de confidencialidad y acceso por rol.
Trazabilidad fiscal	La venta neta se recalcula en 22% de las filas.	Medio: el pipeline debe conservar el dato original.
Decisión y explicabilidad	El modelo alerta; decide Finanzas. Árbol explicable, con reglas sin sentido de negocio.	Medio: alto si se usa para evaluar encargados.

Scoring legal del caso

Dimensión legal	Score	Riesgo principal	Acción antes del go-live
Protección de datos personales	3	Sin datos personales en el modelo	Documentar el alcance: e-commerce excluido
Seguridad y control de accesos	2	Externos con acceso a márgenes	Acuerdo de confidencialidad y accesos por rol
Conservación y trazabilidad fiscal	2	Venta neta recalculada	Guardar dato original y regla de ajuste
Contratos con proveedores externos	2	Data Scientist y Data engineer externos	Cláusulas de confidencialidad y propiedad
Explicabilidad del modelo (IA)	2	Reglas sin sentido de negocio y error desparejo	Uso solo para priorizar revisiones, con revisión humana
PROMEDIO GLOBAL	**2,2**	**Viable con condiciones**	

Escala: 1,0 a 1,5 no factible · 1,6 a 2,5 viable con condiciones · 2,6 a 3,0 factibilidad alta.

Marco regulatorio aplicable al caso

Normativa	Qué regula en este proyecto	Riesgo de incumplimiento	Mitigación
Ley 25.326 de Protección de Datos Personales	No aplica al modelo: usa tienda-mes agregado. Aplicaría si se suman las ventas e-commerce (nombre y DNI) o datos de encargados.	Bajo mientras se respete el alcance	Documentar el alcance y revisar ante cualquier fuente nueva
Lineamientos de la AAIP sobre IA y decisiones automatizadas	Transparencia y revisión humana cuando un sistema influye en decisiones.	Medio si el resultado se usa sobre personas	El tablero informa; decide Finanzas, con registro
ARCA (ex AFIP) · conservación de registros	La venta neta recalculada no puede reemplazar al registro original.	Medio: diferencias no explicables ante una auditoría	Conservar dato original, regla de ajuste y fecha
Seguridad de la información	Costos y márgenes son información comercial confidencial.	Medio: acceso amplio a datos sensibles	Accesos por rol y entorno en la nube con cifrado

Veredicto legal y plan de acción

Veredicto legal: viable con condiciones · score 2,2. Ningún riesgo es bloqueante si las acciones se ejecutan antes del go-live.

Acción legal requerida	Responsable	Plazo	Costo	Si no se ejecuta
Firmar acuerdos de confidencialidad con los perfiles externos	Dirección y Legal	Antes de dar acceso a los datos	Horas internas	Exposición de márgenes y costos
Definir accesos por rol al tablero y a la base	Sistemas	Antes del go-live	Incluido en el ETL	Todos ven todo
Guardar dato original y regla de ajuste de la venta neta	Data engineer	Durante el ETL	Incluido en el ETL	Cifras no auditables
Política de uso: el tablero no evalúa el desempeño de encargados	Dirección y Finanzas	Antes del go-live	Una reunión	Decisiones injustas sobre personas

Veredicto de la evaluación del modelo

Nivel	Evidencia	Veredicto
1 · Técnico	Datos reales: AUC de validación 0,53 y de test 0,44; validación temporal inestable. Drift por promociones.	No apto para producción
2 · Económico y estratégico	Ni un modelo perfecto paga el proyecto (USD 4.312 por año contra USD 30.620).	No viable
3 · Operativo	Finanzas absorbe hasta 8 alertas por mes; el costo llega con demora y las promociones no están integradas.	Viable con condiciones
Legal	Sin datos personales. Score 2,2: confidencialidad, trazabilidad y revisión humana.	Viable con condiciones

Decisión: no llevar el modelo a producción. Avanzar con el MVP de automatización de la Parte B y acumular datos del nuevo régimen de promociones.

Criterio para reabrir: en un test nuevo, precisión ≥ 0,44 y recall ≥ 0,50, y un valor en juego que justifique el costo.

RIESGOS, DEPENDENCIAS Y LIMITACIONES

¿Qué puede salir mal, de quién dependemos y qué no puede hacer el proyecto?

Definición

Riesgo: algo que puede ocurrir y afectar el proyecto. Se mide por probabilidad e impacto.

Dependencia: algo que el proyecto necesita de otra área para avanzar.

Limitación: algo que el proyecto, tal como está planteado, no puede hacer. No es un riesgo: es un hecho.

¿Qué preguntas hacernos?

Cada brecha técnica no resuelta, ¿qué riesgo genera?

¿Cuál es el supuesto económico más frágil?

¿Qué acción legal sin ejecutar puede bloquear?

¿Qué debilidad del modelo puede repetirse?

¿Qué no le podemos prometer al usuario?

Regla: "monitorear" no es una mitigación si no dice qué se mide, quién lo mide y con qué umbral.

De los hallazgos a los riesgos

Hallazgo técnico	Consecuencia económica	Consecuencia legal
Drift por las promociones de 2024	El valor cae de validación a test.	Hace falta monitoreo y trazabilidad de versiones.
Reglas sin sentido de negocio	Los usuarios no confían: baja la adopción.	No se puede justificar una decisión puntual.
Peor desempeño en tiendas chicas	Más falsas alarmas: más costo de revisión.	Trato desigual si se evalúa a encargados.
Pocos casos positivos (19 en entrenamiento)	El techo del modelo es bajo.	Sin efecto legal directo.

Matriz de riesgos del caso

Riesgo	Bloque	Prob.	Impacto	Estrategia	Acción concreta
Tabla de equivalencias de tiendas sin validar	Técnico	A	A	Mitigar	Operaciones valida el mapeo T01–T15 contra S001–S028 antes del ETL
Nadie mantiene el pipeline después de la entrega	Técnico	M	A	Mitigar	Nombrar responsable antes del go-live
La automatización ahorra menos del 52% del trabajo manual	Económico	M	A	Mitigar	Medir horas reales en el primer cierre mensual
Sobrecosto del MVP de 50%	Económico	M	M	Aceptar	Contingencia de 10%; revisar alcance si se supera
Uso del tablero para evaluar a encargados	Legal	B	A	Evitar	Política de uso aprobada por Dirección
Finanzas no adopta el tablero	Organizacional	M	A	Mitigar	Co-diseñar el tablero con 2 usuarios clave
El sponsor cambia de prioridades	Organizacional	M	M	Aceptar	Hitos cortos con resultados visibles cada mes
Nuevo cambio en la política de promociones	Entorno	A	M	Mitigar	Seguir la participación de ventas con promoción
Se retoma el modelo sin señal suficiente	Modelo	M	A	Evitar	Reabrir solo si se cumplen los criterios del veredicto

Escala: Alta (A) · Media (M) · Baja (B). Estrategia: mitigar, aceptar, transferir o evitar.

Dependencias y limitaciones

Dependencia	De quién depende	Para qué hito	Estado actual
Validar el objetivo de margen de 40%	Finanzas y Comercial	Definir la alerta del tablero	Pendiente
Validar la tabla de equivalencias	Operaciones y Sistemas	Cierre del ETL	Pendiente
Nombrar responsable de mantenimiento	Dirección	Go-live	Sin nombrar

Limitación	Implicancia para el usuario
No anticipa: muestra lo que ya pasó	El tablero avisa al cierre del mes; no predice qué tienda va a caer.
Costo histórico aproximado	El margen de meses viejos es una estimación: sirve para tendencias, no para auditar.
No separa contexto de operación	Una caída por inflación o por promociones se ve igual que una por mala gestión.
Solo tiendas físicas	El e-commerce queda afuera del análisis.

ITBA
Instituto Tecnológicc
de Buenos Aires

MÁS INFORMACIÓN > **www.itba.edu.ar**